

Task1

November 11, 2018

```
In [1]: import time
import pandas as pd
import numpy as np
```

Прочитаем файл с данными о выходе из строя серверов:

```
In [2]: data = pd.read_csv("6.csv.xls", header=None, names=["time"])
```

Посмотрим на первые несколько ячеек:

```
In [3]: data.head()
```

```
Out[3]:
```

	time
0	lambda = 88
1	t_0 = 300
2	t = 90000
3	58.3458
4	117.1273

Как можно увидеть в первых трех заданы значения величин λ (или $\frac{1}{\lambda}$), t_0 и t . Запишем их в соответствующие переменные и оставим в нашей таблице только времена выхода из строя серверов:

```
In [4]: lambd = 88
t_0 = 300
t = 90000
data = data[3:]
```

```
In [5]: data.head()
```

```
Out[5]:
```

	time
3	58.3458
4	117.1273
5	303.7976
6	481.9694
7	496.6469

Для удобства сделаем из этих данных массив:

```
In [6]: values = np.array(data.values, dtype=float)
```

Определим какой же нам на вход дали параметр: λ или $\frac{1}{\lambda}$. Мы знаем, что времена между i -ым и $i+1$ -ым моментами выхода из строя серверов являются независимыми в совокупности и имеют Экспоненциальное распределение с параметром λ . Таким образом мы можем считать, что данные случайные величины - это выборка из Экспоненциального распределения. Так как $E\bar{X} = EX_1 = \frac{1}{\lambda}$, то посчитав выборочное среднее можно определить параметр λ . Для этого сдвинем наши данные на 1 вправо и от исходных данных отнимем данные сдвинутые на один, таким образом как раз получим время между выходами серверов из строя. После этого возьмем их среднее.

```
In [7]: np.mean(values[1:] - np.roll(values, 1)[1:])
```

```
Out[7]: 86.6530113113113
```

Как можно заметить среднее значение приблизительно равно значению, которое нам дали в таблице, таким образом нам на вход дали не параметр λ , а $\frac{1}{\lambda}$. Заменяем это в нашей переменной, а также для наглядности результатов уменьшим t_0 в 100 раз

```
In [8]: lambd = 1 / lambd
        t_0 = t_0 // 100
```

Теперь создадим функцию, которая будет каждые t_0 секунд выводить значение величины $E(N_t|N_{kt_0})$, где $k \in N$. Для начала посчитаем эту величину в явном виде:

$$\begin{aligned} E(N_t|N_{kt_0}) &= E(N_t - N_{kt_0} + N_{kt_0}|N_{kt_0}) = E(N_t - N_{kt_0}|N_{kt_0}) + \\ &+ E(N_{kt_0}|N_{kt_0}) = E(N_t - N_{kt_0}) + N_{kt_0} = \lambda(t - kt_0) + N_{kt_0}. \end{aligned}$$

Здесь мы воспользовались линейностью условного математического ожидания, а также тем, что $N_t - N_{kt_0}$ не зависима с N_{kt_0} и $N_t - N_{kt_0}$ имеет Пуассоновское распределение с параметром $\lambda(t - kt_0)$.

В нашем случае, ограничим время работы 70 секундами. Можно также настроить этот параметр, передав в переменную stop время окончания программы.

```
In [24]: def count(stop=None):
        current_not_working = 0
        k = 0
        while (stop is None or k * t_0 <= stop) and current_not_working < len(values):
            while current_not_working < len(values) \
                and k * t_0 >= values[current_not_working]:
                current_not_working += 1
            print("E(N_t|N_{}) = ".format(k * t_0), lambd * (t - k * t_0)
                  + current_not_working)
            time.sleep(t_0)
            k += 1

        count(stop=70)
```

```
E(N_t|N_0) = 1022.7272727272727
E(N_t|N_3) = 1022.6931818181819
E(N_t|N_6) = 1022.659090909091
```

```

E(N_t|N_9) = 1022.625
E(N_t|N_12) = 1022.5909090909091
E(N_t|N_15) = 1022.5568181818182
E(N_t|N_18) = 1022.5227272727273
E(N_t|N_21) = 1022.4886363636364
E(N_t|N_24) = 1022.4545454545455
E(N_t|N_27) = 1022.4204545454546
E(N_t|N_30) = 1022.3863636363636
E(N_t|N_33) = 1022.3522727272727
E(N_t|N_36) = 1022.3181818181819
E(N_t|N_39) = 1022.284090909091
E(N_t|N_42) = 1022.25
E(N_t|N_45) = 1022.2159090909091
E(N_t|N_48) = 1022.1818181818182
E(N_t|N_51) = 1022.1477272727273
E(N_t|N_54) = 1022.1136363636364
E(N_t|N_57) = 1022.0795454545455
E(N_t|N_60) = 1023.0454545454546
E(N_t|N_63) = 1023.0113636363636
E(N_t|N_66) = 1022.9772727272727
E(N_t|N_69) = 1022.9431818181819

```

Посмотрим на несколько последних ячеек в нашей таблице:

```
In [136]: data.tail()
```

```

Out[136]:
           time
998  85857.0263
999  85964.9352
1000 86227.3704
1001 86424.2154
1002 86624.7041

```

Так как в нашем случае $t = 90000$, то действительно количество упавших серверов должно быть приблизительно немного больше 1000, что и предсказывает величина $E(N_t|N_s)$.

Вывод: с помощью условных матожиданий можно довольно точно предсказывать будущие события на основе текущих событий, в случае, если знать их распределение. Это следует из того, что по формуле полной вероятности: $E(E(N_t|N_s)) = EN_t$, поэтому наши предсказываемые данные не должны сильно отличаться от истинных.